Machine Translated by Google

O Continuum de Funções da IA: Desfocando as Fronteiras Entre a pesquisa e a engenharia

Deepak Babu Piskala

Autores colaboradores: prdeepak.babu@gmail.com;

Resumo

A rápida expansão das redes neurais profundas e dos grandes modelos de linguagem eliminou a antiga e clara divisão entre "pesquisa" e "engenharia" em organizações de IA. Com base em descrições de cargos públicas, processos de contratação e narrativas organizacionais de laboratórios e empresas de tecnologia líderes, propomos o Continuum de Funções em IA: um espectro no qual Cientistas de Pesquisa, Engenheiros de Pesquisa, Cientistas Aplicados e Engenheiros de Aprendizado de Máquina compartilham atribuições sobrepostas. Competências essenciais, como design de sistemas distribuídos, treinamento e otimização em larga escala, experimentação rigorosa e pesquisa voltada para publicação, agora estão amplamente distribuídas entre os diferentes cargos. Tratar as funções como fluidas, em vez de isoladas, encurta os ciclos de pesquisa à produção, melhora a velocidade de iteração e fortalece o aprendizado organizacional. Apresentamos uma taxonomia de competências, mapeamos essas competências para cargos comuns e discutimos as implicações para contratação, planos de carreira e desenvolvimento profissional em empresas de IA modernas.

Palavras-chave: organizações de IA; engenharia de pesquisa; ciência aplicada; engenharia de aprendizado de máquina; taxonomia de funções; sistemas sociotécnicos

1 Introdução

Na era das redes neurais profundas e dos grandes modelos de linguagem (LLMs), a separação tradicional entre funções de “pesquisa” e funções de “engenharia” em IA tem se dissolvido cada vez mais. O desenvolvimento de sistemas de IA de última geração agora exige conjuntos de habilidades híbridas: espera-se que os pesquisadores escrevam código escalável e que os engenheiros contribuam para inovações algorítmicas. As principais organizações de IA começaram a reconhecer explicitamente essa convergência. Por exemplo, a Anthropic observa que “os engenheiros aqui fazem muita pesquisa e os pesquisadores fazem muita engenharia”, observando que a fronteira entre os dois “se dissolveu com o advento dos grandes modelos” [1]. Este artigo de posicionamento explora o Continuum de Funções em IA emergente, onde Cientistas de Pesquisa em IA, Engenheiros de Pesquisa,

arXiv:2601.06087v1

Machine Translated by Google

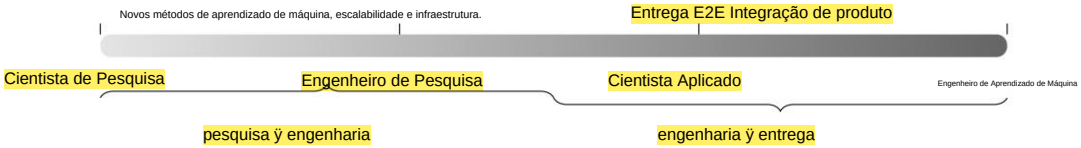

Figura 1: Continuidade de Funções. O Cientista de Pesquisa (CP), Engenheiro de Pesquisa (EP), Aplicado Cientista (AS) e Engenheiro de Aprendizado de Máquina (MLE) existem em um espectro — desde a criação de métodos inovadores para a integração da produção, em vez de como caixas isoladas. O gradiente e as sobreposições suaves Destacar que as equipes frequentemente abrangem múltiplas atribuições simultaneamente, dependendo do produto. maturidade e necessidades organizacionais.

Cientistas aplicados e engenheiros de aprendizado de máquina compartilham cada vez mais áreas de atuação em comum. Responsabilidades na criação, dimensionamento e implementação de modelos avançados de IA.

2 Funções Híbridas em Organizações Líderes em IA

Os principais laboratórios de IA e empresas de tecnologia exemplificam como as funções de pesquisa e engenharia são estruturado para sobreposição:

- OpenAI: A OpenAI contrata Engenheiros de Pesquisa juntamente com Cientistas de Pesquisa, esperando que eles construam sistemas de IA inovadores e avancem na pesquisa fundamental. O trabalho A descrição para um Engenheiro de Pesquisa enfatiza "sólidas habilidades de engenharia (por exemplo, projetar e aprimorar um sistema de aprendizado de máquina distribuído em larga escala), escrita" código de aprendizado de máquina livre de erros e desenvolvimento da ciência por trás dos algoritmos"[2]. OpenAI observa explicitamente que os resultados mais inovadores em aprendizado profundo são obtidos em escala massiva, exigindo engenheiros familiarizados com grandes sistemas distribuídos[2]. Em Na prática, as equipes de pesquisa da OpenAI são multifuncionais, onde a experiência em engenharia é fundamental. É considerado fundamental para os futuros avanços da IA.
- Antrópico: O termo antropológico evita deliberadamente uma distinção nítida entre pesquisadores. e engenheiros. Todos os funcionários técnicos compartilham o título único de "Membro da Equipe Técnica". e a empresa relata que "todos os nossos artigos têm engenheiros como autores, e frequentemente como primeiro autor"[1], sublinhando que as contribuições para a investigação provêm de ambos trilhas. A antropologia valoriza tanto a perspicácia da pesquisa quanto a habilidade de implementação em cada contratar, refletindo sua crença de que novas e ousadas capacidades de grande porte emergem de estreitas relações. Colaboração entre pesquisadores e engenheiros. Essa fluidez entre "engenheiro e pesquisador" é uma prática consciente. parte da cultura de equipe da Anthropic[1].
- DeepMind (Google DeepMind): A DeepMind emprega Engenheiros de Pesquisa que "liderar os esforços no desenvolvimento e na ampliação de novos métodos algorítmicos que impulsionem a fronteira da IA"[3]. Essas funções combinam inovação algorítmica com engenharia pesada: a DeepMind busca "pensadores criativos com forte experiência em design de algoritmos e habilidades de programação", incluindo experiência em arquiteturas de aprendizado de máquina, treinamento distribuído e otimização da taxa de transferência de grandes modelos[3]. Um DeepMind O Engenheiro de Pesquisa é responsável por "projetar, implementar, dimensionar e avaliar modelos e protótipos de software", e por acelerar a pesquisa através da construção de pipelines robustos de dados e treinamento[3]. Eles trabalham em estreita colaboração com cientistas de pesquisa;

Machine Translated by Google

Como explica uma das descrições de vagas da DeepMind, os Engenheiros de Pesquisa desenvolvem "infraestrutura de software escalável para apoiar o desenvolvimento de novos algoritmos e arquiteturas" em busca de avanços [3]. Essa estreita parceria torna tênue a linha divisória entre quem inventa uma ideia e quem a implementa, já que ambos os papéis contribuem tanto para o código quanto para a pesquisa.

• Meta (Facebook AI): A Meta AI tende a usar o título de Cientista de Pesquisa mesmo para funções que envolvem engenharia significativa. Na prática, muitos "Cientistas de Pesquisa" na Meta se envolvem no desenvolvimento de software e infraestrutura. Como descreve um novo contratado, "a Meta contrata cientistas de pesquisa para desempenhar funções tanto de pesquisa quanto de engenharia de software; o que eles realmente fazem depende da equipe"[4]. Por exemplo, um Cientista de Pesquisa (doutor) na área de pesquisa de Sistemas e Infraestrutura da Meta observou que o processo de entrevista foi essencialmente uma entrevista padrão de engenharia de software e que a função era "mais semelhante a um cargo de engenheiro de software de nível intermediário", esperando que o cientista "escrevesse principalmente software para backend/ferramentas".[4] A Meta também possui Engenheiros de Pesquisa em certas equipes (por exemplo, equipes de linguagem generativa), que são engenheiros de software experientes com profundo conhecimento em IA[5]. No geral, as equipes de IA da Meta são frequentemente multifuncionais e a contribuição de um indivíduo pode abranger desde pesquisa de ponta (por exemplo, desenvolvimento de uma nova técnica de modelo) até engenharia (por exemplo, codificação do pipeline de treinamento ou implantação do modelo em um produto). O equilíbrio exato varia de equipe para equipe, mas a cultura da empresa incentiva os pesquisadores a trabalharem diretamente com o código e os engenheiros a se envolverem em experimentação. • Amazon: As funções relacionadas à IA na Amazon misturam explicitamente atividades de pesquisa e engenharia sob títulos como Cientista Aplicado e Cientista de Pesquisa. De acordo com a liderança de IA da Amazon, "espera-se que cientistas de pesquisa e aplicados tenham profundo conhecimento em uma disciplina científica orientada por dados... [e] o desenvolvimento de código de software é uma habilidade essencial esperada dos cientistas aplicados, pois eles estão profundamente envolvidos em levar seus algoritmos à produção."[6] Em outras palavras, um Cientista Aplicado na Amazon é tanto inventor quanto engenheiro, levando modelos da ideia inicial à execução em escala Amazon. As vagas para Cientistas Aplicados geralmente exigem proficiência com ferramentas de big data e sistemas distribuídos. Por exemplo, um anúncio destaca a experiência com "estruturas populares de aprendizado profundo, como MXNet e TensorFlow" e "sistemas distribuídos de grande escala, como Hadoop e Spark" como qualificações preferenciais[7].

As principais responsabilidades dos cientistas da Amazon incluem projetar novos modelos de ML e "trabalhar lado a lado com nossos engenheiros para entregar alterações de código [para] sistemas de produção de alto desempenho", lidando com conjuntos de dados muito grandes; mesmo cargos de Cientista Aplicado júnior mencionam "trabalhar com sistemas distribuídos de dados" e fazer parceria com equipes de produto para construir soluções de ML[8]. O uso do título "Cientista Aplicado" pela Amazon denota, portanto, um trabalho híbrido que avança o estado da arte em ML, ao mesmo tempo que garante que as soluções sejam implementadas e escaláveis na infraestrutura da AWS. • Microsoft: A Microsoft divide sua área de atuação entre a divisão de pesquisa pura (Microsoft Research, onde os cargos são intitulados Pesquisador) e cargos de IA voltados para produtos, intitulados Cientista Aplicado ou Engenheiro de ML, em equipes como Azure AI ou Office. Nas equipes de produto, um Cientista Aplicado é explicitamente um cargo interdisciplinar. Por exemplo, uma vaga para o Office AI descreve "um cargo de liderança na interseção de ciência aplicada".

Machine Translated by Google

"Aprendizado de máquina, grandes modelos de linguagem e inteligência multimodal" – espera-se que o cientista ajude a definir as funcionalidades do produto, aproveitando as pesquisas mais recentes.
Outra vaga da Microsoft para Cientista Aplicado II (equipe do OneNote) descreve a missão como "entregar cenários de IA de alta qualidade", o que envolve "adotar as tecnologias de aprendizado de máquina mais recentes" e medir o impacto do modelo em um produto real. Esses cientistas trabalham em conjunto com engenheiros de software para integrar modelos (como os recursos do Copilot) em aplicativos voltados para o usuário. Enquanto isso, as vagas de Pesquisador da Microsoft Research focam em pesquisa fundamental e geralmente exigem doutorado e publicações, mas mesmo na MSR, espera-se que os pesquisadores possam prototipar suas ideias (geralmente em código) e colaborar com equipes de engenharia para transformar pesquisas bem-sucedidas em produtos. A introdução de recursos de IA em larga escala pela Microsoft (como os Copilots com tecnologia GPT) levou a uma colaboração muito estreita entre cientistas de pesquisa, cientistas aplicados e engenheiros – efetivamente um continuum de funções, cada uma contribuindo com diferentes conhecimentos para os mesmos objetivos de implementação de IA.

No mercado, muitos profissionais sabem executar tarefas. Mas quem tem mentalidade de pesquisa consegue:

Resolver problemas complexos
Inovar (algo muito valorizado hoje)
Tomar decisões mais inteligentes e embasadas
Se adaptar melhor a mudanças

"Esse processo sempre foi feito assim." -> "Será que existe um jeito mais eficiente? Vamos testar e medir."

Ser um engenheiro com viés de pesquisa significa que você não apenas aplica soluções prontas, mas também:

questiona como melhorar
analisa dados antes de decidir
testa hipóteses
cria soluções novas, em vez de só repetir o que já existe

Em todas essas organizações, observamos uma tendência clara: funções que antes eram distintas estão convergindo. Cientistas de pesquisa frequentemente programam em grande escala e se preocupam com a implementação, enquanto engenheiros (engenheiros de pesquisa, engenheiros de aprendizado de máquina) contribuem para o design de algoritmos e até mesmo são coautores de artigos. Os títulos podem variar de empresa para empresa, mas as expectativas de um modelo híbrido são consistentes. Como a OpenAI bem observou, "a engenharia desempenha um papel fundamental na maioria dos grandes avanços em IA"[2] – portanto, espera-se que todos na equipe de IA tragam alguma habilidade em engenharia e alguma mentalidade de pesquisa para o projeto.

3. Habilidades e responsabilidades técnicas compartilhadas entre as diversas áreas Funções

Devido a essa convergência, existe agora um conjunto essencial de competências e responsabilidades técnicas comuns entre as funções de pesquisa e engenharia nas equipes de IA:

• Sistemas Distribuídos e Infraestrutura Escalável: A capacidade de projetar e trabalhar com sistemas de computação distribuída é essencial tanto para pesquisadores quanto para engenheiros que desenvolvem modelos avançados. O treinamento de redes neurais profundas modernas (como Transformers com bilhões de parâmetros) exige a divisão do trabalho entre várias GPUs/TPUs e máquinas. Por exemplo, a vaga de Engenheiro de Pesquisa da OpenAI busca explicitamente experiência com "sistemas de aprendizado de máquina distribuídos em larga escala"[2]. Da mesma forma, espera-se que os Cientistas Aplicados da Amazon estejam familiarizados com sistemas distribuídos de grande escala (como Hadoop e Spark), além da teoria de aprendizado de máquina. Os Engenheiros de Pesquisa da DeepMind são contratados para "desenvolver infraestrutura de software escalável" para novos algoritmos[3] e precisam estar familiarizados com infraestrutura de treinamento e inferência distribuída. Na prática, independentemente do cargo, um profissional de IA que trabalha com modelos de ponta deve compreender o paralelismo [9, 10] (treinamento paralelo de dados e modelos), a arquitetura de computação em cluster e, possivelmente, plataformas em nuvem ou ferramentas de HPC. Isso garante que as ideias possam ser testadas e implementadas na escala em que surgem resultados de última geração. • Arquitetura de Modelos e Compreensão Algorítmica: O conhecimento profundo das arquiteturas de modelos de aprendizado de máquina (por exemplo, redes Transformer, CNNs, algoritmos de aprendizado por reforço) não é mais domínio exclusivo de "pesquisadores". Engenheiros que implementam esses modelos também precisam de conhecimento aprofundado sobre o assunto.

Machine Translated by Google

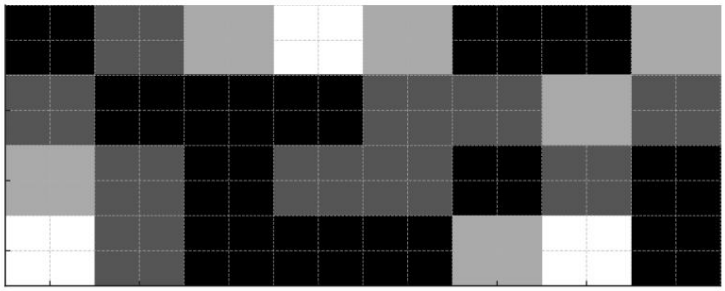

Figura 2: Mapa de calor de envolvimento por função × habilidade. Células mais escuras indicam maior envolvimento típico de uma função nessa habilidade (nenhum ÿ forte). A visualização enfatiza as sobreposições e as forças complementares entre Cientistas de Pesquisa (CP), Engenheiros de Pesquisa (EP), Cientistas Aplicados (CA) e Engenheiros de Aprendizado de Máquina (EAM), tornando as competências compartilhadas e as áreas de foco específicas de cada função evidentes à primeira vista.

É necessário compreender como os modelos funcionam para otimizá-los e depurá-los. Por outro lado, os pesquisadores que propõem novas arquiteturas muitas vezes as implementam pessoalmente. Muitas vagas de emprego refletem essa sobreposição: a DeepMind espera que seus Engenheiros de Pesquisa tenham experiência em arquiteturas de aprendizado de máquina e design de algoritmos[3], enquanto as funções de cientista na Amazon exigem a compreensão de "métodos modernos, como aprendizado profundo" para lidar com problemas do mundo real. Em resumo, espera-se que ambos os tipos de função compreendam a teoria por trás dos modelos (para contribuir com ideias inovadoras ou melhorias) e a prática de codificá-los. Um Cientista de Pesquisa pode criar uma nova otimização para Transformers, mas um Engenheiro de Pesquisa/ML ajudará a integrá-la, e ambos precisam falar a linguagem das arquiteturas, funções de perda e avaliação estatística. • Otimização e Eficiência do Treinamento: Expandir as fronteiras com modelos grandes geralmente depende de tornar o treinamento mais rápido, mais eficiente em termos de memória e mais robusto.

Habilidades em programação de GPU e otimizações de treinamento distribuído (como acumulação de gradientes, precisão mista, otimização de memória e pipelines de dados eficientes) são muito requisitadas em diversas funções. A OpenAI valoriza "implementações de alto desempenho de algoritmos de aprendizado profundo" como um diferencial, mesmo para contratações voltadas à pesquisa[2]. A DeepMind busca, de forma semelhante, profissionais com experiência em "escalonamento de modelos [e] otimização de throughput" em seus sistemas de aprendizado de máquina[3]. Resolver esses problemas exige tanto conhecimento de engenharia de baixo nível (conhecimento de sistemas) quanto uma compreensão de alto nível do processo de aprendizado. Por exemplo, considere o desafio de acelerar o treinamento distribuído: pode-se aprimorar o algoritmo all-reduce para sincronização de gradientes (uma solução sistêmica) ou ajustar o algoritmo de aprendizado de máquina para exigir sincronização menos frequente (uma solução algorítmica). Como observou um engenheiro de pesquisa, "às vezes, a solução correta pode ser uma solução de ciência da computação... em uma situação diferente, a solução pode ser de aprendizado de máquina (por exemplo, atualizar parâmetros com menos frequência e corrigir isso com amostragem por importância). A capacidade de raciocinar sobre as compensações entre

Machine Translated by Google

Essas opções são o que torna um engenheiro de pesquisa valioso."[11] Essa capacidade de equilibrar a otimização de sistemas e a inovação em aprendizado de máquina é cada vez mais esperada tanto de pesquisadores quanto de engenheiros em projetos de IA de grande escala. • Frameworks e ferramentas de aprendizado de máquina: A proficiência com frameworks de desenvolvimento de aprendizado de máquina (TensorFlow, PyTorch, JAX, etc.) e ferramentas relacionadas é universalmente esperada. Cientistas de pesquisa usam esses frameworks para prototipar novos modelos, enquanto engenheiros de pesquisa/aprendizado de máquina os usam para implementar, otimizar e implantar modelos.
Os requisitos de trabalho da DeepMind listam explicitamente experiência em frameworks como JAX e familiaridade com a "infraestrutura de treinamento/inferência" em torno deles[3]. A Amazon busca habilidades semelhantes (por exemplo, MXNet, TensorFlow, PyTorch) em cientistas aplicados[7].
Além disso, saber usar ferramentas para rastreamento, avaliação e implantação de experimentos (de notebooks Jupyter a Kubernetes, dependendo da função) faz parte do conjunto de habilidades compartilhadas. Espera-se que todos na equipe contribuam, por exemplo, para uma base de código PyTorch compartilhada ou para depurar uma execução de treinamento em um cluster. Assim, a noção de que um pesquisador escreve apenas código de pesquisa e um engenheiro lida apenas com "código de produção" está desaparecendo — ambos frequentemente usam as mesmas ferramentas para escrever código confiável e escalável (com testes e otimizações apropriados) que eventualmente se tornará parte de um produto ou plataforma de pesquisa.

• Habilidades em Pipeline de Dados e Experimentação: Gerenciar conjuntos de dados em larga escala, pré-processar dados e alimentar o treinamento de forma eficiente é uma responsabilidade frequentemente compartilhada entre as diferentes funções. Um Engenheiro de ML pode se concentrar na construção de um pipeline de dados robusto, mas um Cientista de Pesquisa também precisa entender as questões relacionadas aos dados para garantir a validade dos experimentos. Muitos Engenheiros de Pesquisa acabam criando ou aprimorando ferramentas internas para manipulação de dados e avaliação de modelos, visando acelerar a pesquisa. Por exemplo, a criação de suítes de avaliação ou o gerenciamento de registro/monitoramento para grandes experimentos podem ser responsabilidades de um engenheiro de pesquisa, mas o cientista que utiliza a ferramenta também precisa saber como ela funciona. Em resumo, ambas as funções se envolvem na "infraestrutura" dos experimentos de ML – carregamento de dados, escolha de métricas, execução de avaliações – especialmente com os conjuntos de dados massivos usados para aprendizado profundo.
• Colaboração Interfuncional: Como a implementação de um modelo de IA, da ideia ao produto, envolve muitas etapas, o trabalho em equipe interfuncional é fundamental. Uma equipe moderna de IA geralmente inclui cientistas de pesquisa, cientistas aplicados, engenheiros de software, engenheiros de dados e gerentes de produto trabalhando em conjunto. Portanto, todos os membros da equipe devem ter habilidades de colaboração e comunicação, além de algum conhecimento das áreas de atuação dos outros. A Amazon destaca que seus cientistas "fornecem parceria técnica para... equipes e organizações que desenvolvem soluções de aprendizado de máquina" – o que significa que um cientista aplicado pode coordenar-se de perto com engenheiros de produto ou equipes de plataforma de dados. Ao mesmo tempo, os engenheiros das equipes de IA participam de discussões de pesquisa, ajudando a moldar as direções da pesquisa com insights práticos (por exemplo, como um modelo pode ser integrado a um sistema real). Muitas empresas incentivam ativamente essa colaboração fluida. Por exemplo, espera-se que os cientistas da Amazon "trabalhem em parceria com... Engenheiros de Desenvolvimento de Software" e até mesmo os orientem em aprendizado de máquina.

Os engenheiros de pesquisa da DeepMind "trabalham em estreita colaboração com outros engenheiros e cientistas para fazer avançar a área"[3], e a estrutura unificada da equipe técnica da Anthropic promove uma troca constante entre as perspectivas de "pesquisa" e "engenharia". O resultado é

Machine Translated by Google

pesquisador impacto no mundo real
engenheiro trabalha com inovação, implementação de novos metodos

que responsabilidades como a implantação de modelos (tradicionalmente uma tarefa de engenharia) e a experimentação científica (tradicionalmente uma tarefa de pesquisa) são frequentemente esforços compartilhados. Um Cientista de Pesquisa pode ajudar a depurar um problema de escalabilidade na implantação, enquanto um Engenheiro de Pesquisa pode ser coautor de um artigo sobre os resultados – cada um contribuindo onde necessário para atingir os objetivos da equipe. • Mentalidade de Pesquisa e Publicação: Curiosamente, muitas funções com foco em engenharia agora também valorizam uma mentalidade de pesquisa e até mesmo experiência em publicação. Não é incomum que Engenheiros de Pesquisa ou Cientistas Aplicados sejam coautores de importantes artigos de pesquisa – na verdade, alguns artigos inovadores (como "Attention Is All You Need" e o relatório técnico do GPT-3 da OpenAI) tiveram tanto engenheiros quanto cientistas como colaboradores principais. Anthropic observa explicitamente que engenheiros foram os primeiros autores de seus artigos[1]. Empresas como Amazon e Microsoft incentivam cientistas aplicados a publicar em importantes conferências acadêmicas. A lógica é que aqueles que atuam em funções de engenharia frequentemente realizam trabalhos inovadores (implementando um novo método de escalonamento ou aprimorando a eficiência de um modelo) que são valiosos para a comunidade científica. Por outro lado, os pesquisadores são incentivados a considerar o impacto no mundo real, o que significa escrever código com qualidade de produção e, possivelmente, disponibilizar conjuntos de dados ou ferramentas. Essa infusão mútua de rigor científico e prático eleva a produção de toda a equipe. Em resumo, contribuir para a literatura científica, manter-se atualizado com novas descobertas e pensar em termos de impacto da pesquisa agora fazem parte de muitas funções de engenharia – assim como se espera que os pesquisadores produzam sistemas robustos e funcio documentos.

4. Definições de funções e requisitos de competências na prática

Para ilustrar os pontos acima, podemos examinar as expectativas para vários cargos comuns na área de IA. Anúncios e descrições de vagas reais de empresas líderes em IA destacam tanto os focos distintos quanto as habilidades em comum de cada função:

- Cientista de Pesquisa (CP): Este título geralmente designa alguém focado em desenvolver novos algoritmos ou questões de pesquisa fundamentais. Os requisitos típicos incluem um diploma avançado (geralmente um doutorado) em uma área relevante e um sólido histórico de publicações em conferências de alto nível. Espera-se que os Cientistas de Pesquisa tenham profundo conhecimento em áreas como teoria de aprendizado de máquina, PNL, visão computacional, etc., e que gerem ideias de pesquisa originais. No entanto, eles também costumam ser programadores competentes; devem implementar experimentos (geralmente em Python com bibliotecas de ML) para validar suas ideias. Em laboratórios industriais, um CP também costuma ser responsável por levar seus modelos para a produção. Por exemplo, na Meta, um Cientista de Pesquisa pode passar uma parte significativa do tempo programando e até mesmo participar de entrevistas de programação para ser contratado[4]. Na Amazon, os Cientistas de Pesquisa se enquadram na carreira científica mais ampla e são avaliados tanto pela inventividade científica quanto pela capacidade de "aplicar princípios científicos para apoiar invenções significativas" em produtos reais[6]. Em resumo, embora um Cientista de Pesquisa enfatize a inovação na pesquisa, seu conjunto de habilidades geralmente abrange desde derivações matemáticas até a escrita de código eficiente. Eles podem liderar projetos, escrever artigos e prototipar novos modelos e, em muitos casos, repassar implementações robustas para engenheiros para escalonamento, a menos que optem por escalá-las eles mesmos.

Machine Translated by Google

- Engenheiro de Pesquisa (EP): Um Engenheiro de Pesquisa é um exemplo típico de função híbrida. Encontrados em organizações como OpenAI, DeepMind, Anthropic, etc., os Engenheiros de Pesquisa (REs) são engenheiros de software experientes com um sólido conhecimento em aprendizado de máquina (ML). Normalmente, não exigem um doutorado (experiência na indústria ou um mestrado podem ser suficientes), mas espera-se que sejam excelentes em programação, design de sistemas e execução de experimentos. A principal responsabilidade de um RE é frequentemente descrita como "viabilizar, contribuir e acelerar a pesquisa em ML, trazendo expertise em engenharia para os projetos". Na prática, isso significa que os REs implementam novos algoritmos (transformando ideias teóricas em código funcional), configuram treinamentos em larga escala, gerenciam bases de código de modelos e desenvolvem ferramentas para pesquisadores (como pipelines de avaliação ou painéis de visualização). São eles que, por exemplo, garantem que uma nova arquitetura de modelo possa ser treinada em dezenas de GPUs sem falhas, ou que uma ideia seja testada em conjuntos de dados adequados. Mas, além do suporte, os Engenheiros de Pesquisa frequentemente contribuem com novas ideias e melhorias com base em suas descobertas empíricas. As equipes geralmente têm Engenheiros de Pesquisa (ERs) e Cientistas de Pesquisa trabalhando como pares – observa-se que “cientistas de pesquisa e engenheiros de pesquisa... ambos concebem ideias e as implementam”, e podem ser “contribuidores iguais para artigos”.[12] A principal diferença é burocrática (os cientistas podem ter um cargo ou salário mais alto) ou experimental (os cientistas podem ter mais experiência teórica), mas, no dia a dia, um ER pode estar escrevendo código em um dia e pensando em melhorias de algoritmos no dia seguinte. As principais habilidades para ERs incluem forte conhecimento de programação (C++/Python), conhecimento de frameworks de aprendizado de máquina, capacidade de configurar trabalhos de treinamento distribuído, depuração de problemas numéricos e uma boa intuição tanto para o desempenho do software quanto para o comportamento do modelo. Essa função exemplifica a linha tênue: ela se situa exatamente entre a engenharia pura e a pesquisa pura, e diferentes empresas a posicionam ligeiramente mais próxima de um lado ou do outro. (Por exemplo, os Engenheiros de Reengenharia da DeepMind podem tender um pouco mais para a engenharia voltada à pesquisa inovadora, enquanto os Engenheiros de Reengenharia da OpenAI podem treinar diretamente modelos gigantes e, assim, também se envolver na descoberta de pesquisas.)
- Cientista Aplicado / Pesquisador Aplicado: Títulos como Cientista Aplicado (usados na Amazon, Microsoft e outras empresas) indicam uma função focada em aplicar e traduzir pesquisas de IA em produtos ou serviços do mundo real. Essas funções normalmente exigem forte conhecimento em aprendizado de máquina (muitas vezes um doutorado ou experiência equivalente) e a capacidade de escrever código de qualidade para produção. Como a Amazon descreve, um Cientista Aplicado é alguém que "preenche a lacuna entre pesquisa e engenharia, pegando modelos de ponta e fazendo-os funcionar em escala para os clientes". Eles trabalham em equipes orientadas a produtos (por exemplo, Alexa, serviços de IA da AWS, personalização, anúncios) e são responsáveis pelo desenvolvimento completo de soluções de aprendizado de máquina: desde a formulação do modelo, treinamento em grandes conjuntos de dados, até a implantação no ambiente de produção. Um Cientista Aplicado pode estar lendo artigos de pesquisa ou inventando uma nova abordagem de modelagem em um dia e, no dia seguinte, otimizando a latência em um serviço da AWS ou realizando testes A/B de um recurso. As vagas de emprego frequentemente listam uma combinação de habilidades: aprendizado profundo, processamento de dados distribuídos, programação em uma linguagem como Python ou Java e a capacidade de avaliar o impacto nos negócios. Na Amazon, espera-se também que os candidatos sigam os princípios de liderança da empresa, demonstrando visão de negócios e foco no cliente em suas decisões de pesquisa. Os Cientistas Aplicados da Microsoft trabalham de forma semelhante em equipes como a do Bing.

Machine Translated by Google

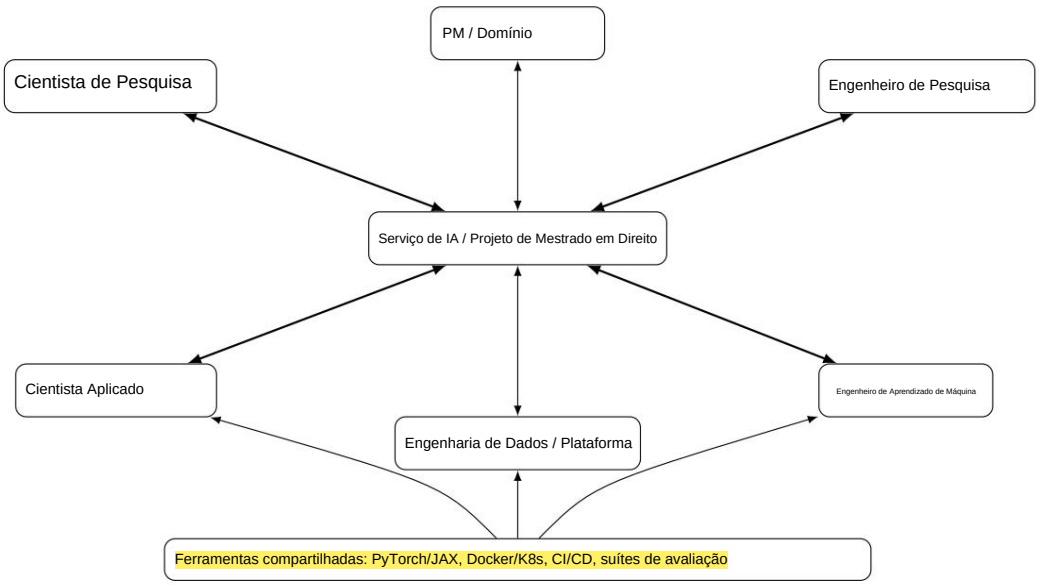

Figura 3: Topologia da equipe multifuncional. Um projeto de IA/LLM está no núcleo, com RS, RE, AS e MLE conectados bidirecionalmente, e parceiros adjacentes (PM/Domínio, Engenharia de Dados/Plataforma) interagindo por meio de ferramentas compartilhadas (por exemplo, CI/CD, K8s, stacks de treinamento/avaliação). O diagrama enfatiza a clara responsabilidade com limites flexíveis que permitem iterações rápidas.

No Office ou no Azure, eles implementam modelos (por exemplo, um LLM para o Office Copilot) e medem como isso melhora a experiência do usuário. Em resumo, o Cientista Aplicado é essencialmente tanto um pesquisador (criando soluções inovadoras) quanto um engenheiro (levando essas soluções à produção), com talvez mais ênfase em gerar impacto para o cliente do que em publicar artigos. Eles frequentemente colaboram com engenheiros de software que integram seus modelos em sistemas maiores, mas os próprios cientistas garantem que os modelos sejam construídos e ajustados corretamente para produção.

usar.

- Engenheiro de Aprendizado de Máquina (Engenheiro de ML): Este título geralmente se refere a uma função mais voltada para a engenharia, especialmente em organizações fora dos laboratórios de pesquisa tradicionais. Um Engenheiro de ML é tipicamente um engenheiro de software especializado na implementação e implantação de modelos de aprendizado de máquina. As principais habilidades incluem a construção de pipelines de dados, a disponibilização de modelos em produção (por exemplo, via APIs ou incorporação em aplicativos) e a otimização do desempenho em tempo de execução (otimização de inferência de CPU/GPU, gerenciamento de memória, etc.). Eles também podem lidar com pipelines de treinamento contínuo, monitoramento do desempenho do modelo em produção e frameworks de teste A/B. Embora não se espere que um Engenheiro de ML invente novos algoritmos de ML do zero, ele precisa entender ML o suficiente para escolher os modelos apropriados e solucionar problemas. Em muitas empresas, os Engenheiros de ML trabalham em estreita colaboração com Cientistas de Dados ou Cientistas de Pesquisa: o cientista pode desenvolver um modelo em um notebook e o Engenheiro de ML irá refatorá-lo em um código robusto, integrando-o aos dados de produção.

Machine Translated by Google

fontes e garantir que seja escalável e atenda aos requisitos de latência. No entanto, à medida que o espectro se torna mais tênue, muitos Engenheiros de ML hoje também experimentam com o ajuste de modelos e contribuem para tarefas voltadas à pesquisa (como engenharia de recursos ou até mesmo a criação de funções de perda personalizadas) e, inversamente, alguns cientistas de pesquisa em equipes de produto acabam implantando modelos eles mesmos. Por exemplo, na Meta, o termo "Engenheiro de ML" às vezes pode ser usado como sinônimo de Engenheiro de Pesquisa ou até mesmo Engenheiro de Software em equipes de IA, indicando uma função que exige fortes habilidades de programação, além de conhecimento em ML. Geralmente, os Engenheiros de ML se destacam na tradução de uma ideia comprovada em um serviço confiável. Seu conjunto de ferramentas pode incluir TensorFlow Serving ou TorchServe, ferramentas de pipeline como Apache Beam ou AWS SageMaker e boas práticas de desenvolvimento de software. Embora o papel do Engenheiro de ML puro possa não ser escrever artigos acadêmicos, é vital para fazer a ponte final de um modelo de IA para um produto utilizável e muitas vezes requer resolução criativa de problemas que se sobrepõe à pesquisa (por exemplo, descobrir como comprimir um modelo grande para implantação móvel pode envolver a pesquisa de técnicas de quantização de modelo[13–15] ou destilação[16]).

Todas essas funções compartilham uma considerável interseção de habilidades. Por exemplo, tanto Engenheiros de Pesquisa quanto Engenheiros de Aprendizado de Máquina precisam saber como lidar com treinamento distribuído; tanto Cientistas de Pesquisa quanto Cientistas Aplicados precisam se manter atualizados com a literatura e também programar em frameworks como o PyTorch. Muitas organizações reconhecem que o título de um funcionário não define rigidamente o que ele faz no dia a dia. É comum ver um Cientista de Pesquisa em uma empresa como o Google ou a Meta dedicando grande parte do tempo à programação e à infraestrutura, enquanto um Engenheiro de Pesquisa ou um Engenheiro de Aprendizado de Máquina pode estar liderando uma iniciativa de pesquisa. Como afirmou uma análise, “Cientistas de pesquisa devem, antes de tudo, ser engenheiros” na prática[12] – o que significa que mesmo aqueles contratados para pesquisa devem implementar e experimentar, não apenas teorizar. E, inversamente, funcionários com foco em engenharia frequentemente contribuem com ideias e melhorias que moldam a direção da pesquisa.

5. Escalando a infraestrutura de IA e a interfuncionalidade Estruturas de Equipe

Uma das principais forças motrizes por trás da continuidade de funções é a enorme complexidade dos projetos de IA modernos. Treinar e implantar modelos de ponta (como GPT-4, PaLM ou Claude) é um empreendimento sociotécnico que exige conhecimentos especializados diversos. A infraestrutura desses modelos — clusters de treinamento distribuídos, estratégias de paralelismo de modelos, conjuntos de dados massivos, integração contínua de atualizações de modelos — não pode ser gerenciada por equipes tradicionais isoladas. Líderes do setor adotaram estruturas de equipes multifuncionais para IA, o que torna ainda mais tênues as fronteiras entre as funções.

Em equipes multifuncionais de IA, indivíduos com diferentes cargos colaboram estreitamente ao longo de todo o ciclo de vida do projeto. Um exemplo concreto é como o escalonamento de modelos de IA é orientado por tarefas. Considere uma equipe trabalhando em um novo modelo de linguagem de grande porte: pesquisadores podem propor melhorias para o modelo, mas os engenheiros de pesquisa escreverão o código para testá-las, e os engenheiros de aprendizado de máquina irão analisar e otimizar o processo de treinamento. Eles devem trabalhar em conjunto para iterar rapidamente. Como Akihiro Matsukawa [11] observou em suas FAQs de Engenharia de Pesquisa, o escalonamento de uma tarefa de treinamento de modelo de grande porte pode apresentar uma escolha entre uma solução sistêmica.

Machine Translated by Google

(algoritmos de rede aprimorados, gerenciamento de memória) e uma solução de modelagem (ajustes algorítmicos para usar os recursos de forma mais eficiente), e decidir a melhor abordagem “requer raciocínio sobre as compensações” entre os domínios[11]. Esse tipo de decisão só pode ser tomado quando os membros da equipe entendem os domínios uns dos outros – por exemplo, o pesquisador entende algumas restrições do sistema e o engenheiro entende alguma teoria de aprendizado de máquina. Assim, as equipes geralmente trabalham juntas, usam as mesmas ferramentas e têm ciclos de comunicação fluidos.

Outro aspecto importante é a implantação do modelo e a integração do produto. Implantar um modelo de IA (especialmente um modelo de aprendizado de máquina que alimenta um produto como o ChatGPT ou um copiloto de IA) não é uma simples entrega, na qual a equipe de pesquisa simplesmente repassa o modelo para a equipe de engenharia. Em vez disso, a implantação é iterativa e colaborativa. Engenheiros de pesquisa e engenheiros de aprendizado de máquina configuram a infraestrutura de serviço, mas também precisam do feedback dos cientistas de pesquisa sobre como lidar com as atualizações do modelo ou avaliar a qualidade dos resultados. Da mesma forma, os cientistas podem precisar estar cientes das limitações descobertas durante a implantação (como limites de memória ou padrões de entrada do usuário em tempo real), o que pode inspirar pesquisas em arquiteturas mais eficientes ou métodos de ajuste rápido. Empresas como Amazon e Microsoft frequentemente integram cientistas diretamente às equipes de produto para que esses ciclos de feedback ocorram diariamente. O resultado é que as funções se misturam: um engenheiro de software pode sugerir uma alteração no modelo para melhorar a latência, ou um pesquisador pode sugerir uma mudança de engenharia (como uma estratégia diferente de computação distribuída) para permitir a exploração de um modelo maior. A equipe como um todo é responsável pelo resultado (um serviço de IA funcional e de alto desempenho), e cada membro contribui com suas habilidades conforme necessário para alcançá-lo.

Organizacionalmente, algumas empresas derrubaram explicitamente as barreiras entre os departamentos de pesquisa e engenharia. A OpenAI, por exemplo, se autodenomina uma "empresa de pesquisa e implementação de IA" e tem muitos membros de equipe com habilidades em ambas as áreas.
A equipe técnica da Anthropic, com sua estrutura focada em uma única área de atuação, é outro exemplo explícito, onde a contratação e as entrevistas são personalizadas para encontrar pessoas que possam contribuir de diversas maneiras, independentemente de sua formação. O Google (após a fusão do Brain e do DeepMind no Google DeepMind) também enfatiza fluxos de trabalho que vão da pesquisa à produção, frequentemente realocando pessoas entre equipes de pesquisa pura e equipes aplicadas. Essa fluidez faz parte de uma cultura emergente de engenharia de IA que valoriza a versatilidade. Novos títulos de cargos como "Cientista de Aprendizado de Máquina" ou "Generalista de IA" surgem até mesmo em startups de IA menores, indicando a expectativa de que uma mesma pessoa possa desempenhar ambas as funções.

Do ponto de vista da gestão de projetos, a combinação de funções pode acelerar o progresso. Em vez de um processo linear (pesquisa ÿ entrega ÿ engenharia ÿ entrega ÿ implantação), equipes multifuncionais iteram em paralelo. Por exemplo, durante o desenvolvimento de um modelo complexo, assim que uma descoberta é encontrada na pesquisa, ela pode ser testada em um ambiente realista pelos engenheiros e, se surgirem problemas, os pesquisadores podem resolvê-los rapidamente. Isso foi essencial em projetos marcantes como o GPT-3 e o GPT-4 da OpenAI, nos quais técnicas inovadoras (como leis de escala [17, 18] ou aprendizado por reforço a partir de feedback humano [19, 20]) tiveram que ser testadas em uma infraestrutura enorme – exigindo uma parceria estreita entre aqueles que inventavam os métodos e aqueles que operavam os clusters. De fato, alguns dos agradecimentos e relatórios desses projetos mencionam o papel crucial do talento em engenharia para alcançar os resultados (mesmo que não nominalmente, devido a contribuições não públicas). Como comunidade, reconhecemos que os grandes avanços em IA agora frequentemente...

Machine Translated by Google

provêm tanto de avanços de engenharia (melhor paralelismo, nova utilização de hardware, etc.) quanto de avanços puramente algorítmicos.

Assim, a pesquisa e a engenharia são vistas como duas facetas do mesmo processo geral de inovação, em vez de processos sequenciais ou separados.

Tendências na estrutura de equipes: Muitas organizações mantêm uma mistura de pessoas com doutorado e pessoas com formação em engenharia de software em cada equipe, em vez de separá-las. Elas ainda podem ter métricas de desempenho diferentes (por exemplo, pesquisadores podem ser avaliados por artigos publicados ou patentes inovadoras, engenheiros pela confiabilidade do sistema e qualidade do código), mas o trabalho diário é interligado. Algumas empresas promovem o rodízio de funcionários por diferentes tipos de projetos para ampliar suas habilidades. A Amazon, por exemplo, tem programas para ajudar cientistas a adquirir habilidades de engenharia e vice-versa.

A Microsoft tem um conceito de "engenheiro de software em aprendizado de máquina" versus "pesquisador", mas nos novos produtos com inteligência artificial, eles efetivamente trabalham juntos. Startups muitas vezes ignoram completamente os títulos em favor de "engenheiro de IA" ou similares, esperando responsabilidade integral tanto pelas tarefas de pesquisa quanto pelas de engenharia.

Em termos de infraestrutura, a ascensão de plataformas e ferramentas comuns também contribuiu para a diluição das funções. O uso de uma plataforma unificada (como TensorFlow ou PyTorch) tanto para experimentação quanto para implantação significa que todos na equipe falam a mesma "língua", até certo ponto. Ferramentas como Docker, Kubernetes ou serviços de aprendizado de máquina na nuvem são usadas por cientistas para executar experimentos e por engenheiros para implantar — esse conjunto de ferramentas comum facilita a troca de tarefas e o auxílio mútuo entre as funções. Quando um pesquisador consegue conteinerizar seu código de treinamento, um engenheiro pode usá-lo diretamente em um pipeline de produção com o mínimo de adaptação. Essa abordagem de aprendizado de máquina no estilo DevOps (às vezes chamada de MLOps) incentiva os pesquisadores a pensarem mais como engenheiros em termos de escrita de código sustentável e incentiva os engenheiros a se adaptarem à natureza rápida e iterativa da pesquisa.

Por fim, as equipes multifuncionais de IA também incluem funções como engenheiros de dados, gerentes de produto, etc., o que exige ainda mais uma comunicação clara. Uma pessoa com perfil de pesquisa precisa explicar os comportamentos ou necessidades do modelo para um gerente de produto, e uma pessoa com perfil de engenharia precisa entender os objetivos científicos que norteiam uma funcionalidade. Tudo isso contribui para um ambiente onde as definições rígidas de funções se tornam menos relevantes em favor de um espectro de especialização – cada membro da equipe possui um perfil de habilidades em formato de T (profundo em algumas áreas, amplo em outras) e as sobreposições entre elas garantem que não haja "lacunas" na transformação de uma ideia em um sistema de IA confiável e implementado.

6 Demanda Organizacional ao Longo do Continuidade entre Pesquisa e Engenharia

O continuum não faz com que as organizações pareçam iguais; ele as inclina. O que varia de acordo com o arquétipo é onde a massa de contratações se concentra ao longo do eixo pesquisa-engenharia e por quê.

Como sugere a Figura 4 , os laboratórios de vanguarda concentram um pequeno número de vagas na área de pesquisa, enquanto as empresas de produtos e plataformas criam muito mais funções voltadas para a engenharia. No entanto, em todos os contextos, as equipes mais eficazes são híbridas e móveis ao longo de toda a escala.

Os laboratórios de modelos de fronteira, que constroem modelos fundamentais de uso geral e a ciência que os envolve, otimizam a descoberta em grande escala. Suas contratações mais frequentes são

Machine Translated by Google

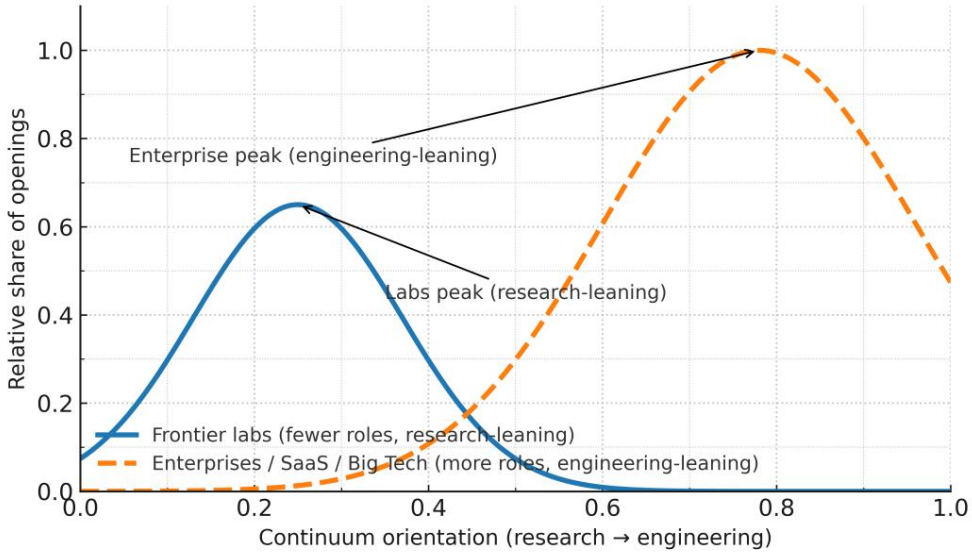

Figura 4: Distribuição ilustrativa das contratações ao longo do espectro pesquisa-engenharia por tipo de organização. Laboratórios de vanguarda apresentam o pico no lado voltado para pesquisa, com menos vagas no total; empresas (IA vertical / SaaS / grandes empresas de tecnologia) apresentam o pico no lado voltado para engenharia, com mais vagas.

Cientistas pesquisadores capazes de desenvolver métodos e esquemas de avaliação, em conjunto com engenheiros de pesquisa aptos a transformar ideias em treinamentos massivos e análises rigorosas. A engenharia é onipresente, mas existe a serviço da aceleração científica: orquestração de clusters, curadoria de dados em larga escala e as plataformas internas de agentes utilizadas para testar modelos, gerar currículos sintéticos e explorar os limites de capacidade. Abstrações de memória e uso de ferramentas são construídos principalmente como instrumentos de pesquisa, e não como produtos externos.

As plataformas de modelos de base (frequentemente provedores de nuvem/API) situam-se mais próximas do centro do continuum. Seu objetivo é operar modelos como serviços confiáveis e expor primitivas adjacentes ao modelo — memória, recuperação, chamada de ferramentas, filtros de segurança e telemetria — como APIs estáveis. Isso direciona a contratação para cientistas aplicados que possam aprimorar estratégias de ajuste fino e roteamento, e para engenheiros de ML/Plataforma que possam tornar o fornecimento previsível em termos de custo, latência e qualidade. A pesquisa persiste, mas está orientada para a eficiência (destilação [16], quantização [13–15]), controlabilidade e segurança. O resultado é a ciência processada: as mesmas ideias de agente [21–24] e memória usadas em laboratórios são reformuladas como recursos que os desenvolvedores podem compor.

Um arquétipo distinto surgiu em torno de frameworks de agentes e ferramentas de desenvolvimento. Essas empresas tratam os agentes como uma pilha de software: planejadores [21] e registros de ferramentas [25] , memória episódica e de longo prazo [26, 27], simuladores para avaliação [28–31], ambientes de teste para execução segura e observabilidade para explicar o que um agente tentou e por quê. A contratação aqui ainda tende para a engenharia, mas com uma forte vertente de pesquisa aplicada.

Machine Translated by Google

em roteamento, autorreflexão e avaliação por design. O trabalho não se concentra tanto em inventar novos modelos básicos, mas sim em tornar o comportamento dos agentes legível, confiável e programável em diversas ferramentas e sistemas de dados.

As empresas de IA vertical e de produtos SaaS são as que mais se aproximam do lado da engenharia, mantendo, ao mesmo tempo, uma linha de pesquisa pragmática. Elas transformam modelos gerais em resultados específicos do domínio, como resolução de suporte ao cliente, assistência de vendas, automação de TI, elaboração de relatórios clínicos ou financeiros, sobrepondo memória (perfis de usuário, histórico de casos, contexto de políticas) e uso de ferramentas (sistema de tickets, CRM, pagamentos, sistemas de conhecimento) em torno de um núcleo de gestão de recursos.
O trabalho diário combina o design de prompt/RAG [32] , o ajuste de guardrail e recompensa/política, a experimentação A/B e a atenção implacável à latência, confiabilidade e custo.
A força de trabalho é composta principalmente por cientistas aplicados e engenheiros de aprendizado de máquina orientados a produtos; a pesquisa surge onde o domínio exige especialização (fala, inteligência de documentos, texto regulamentado).

As grandes empresas de tecnologia que desenvolvem produtos se assemelham a SaaS vertical em escala extrema. Seu foco principal é a engenharia e a experimentação: telemetria com respeito à privacidade, memória entre aplicativos, defesas contra abusos e fraudes, conformidade com políticas e a infraestrutura que permite que os agentes se comuniquem entre sistemas operacionais e suítes de produtividade. Elas ainda contratam pesquisadores, mas geralmente para metodologias de métricas, objetivos de personalização e ciência da segurança que possam sobreviver em escala populacional. A característica prática é que os agentes não são uma demonstração; eles estão integrados a plataformas que milhões de pessoas utilizam.

As empresas da lista Global 2000 que adotaram a tecnologia priorizam a integração, a governança e a confiabilidade em detrimento da inovação. Suas contratações tendem a se concentrar em engenheiros de plataforma para LLMOps (Large Logging Operations), arquitetos de soluções capazes de integrar agentes a sistemas legados e engenheiros de dados/ML (Aprendizado de Máquina) que conseguem implementar governança de recuperação de dados e memória com reconhecimento de PII (Informações Pessoais Identificáveis) dentro das restrições de conformidade. O foco em pesquisa surge apenas em análises regulamentadas ou quando dados proprietários oferecem uma vantagem metodológica. Integradores de serviços e sistemas orbitam esse cenário, adaptando a mesma pilha de tecnologias aos contextos dos clientes e escalando o gerenciamento de mudanças; seu perfil de demanda espelha o das empresas que adotaram a tecnologia, porém com uma cadência de entrega mais robusta e arquiteturas de referência para memória, invocação de ferramentas e avaliação.

Por fim, os ecossistemas de código aberto e os laboratórios acadêmicos fora do grupo de vanguarda fornecem os recursos comuns: métodos, conjuntos de dados e referências que tornam os agentes, a memória e a avaliação reproduzíveis. Suas contratações combinam pesquisa e engenharia em proporções aproximadamente iguais, com profundidade suficiente para propor novas ideias e habilidade suficiente para entregar bibliotecas de fácil manutenção e nas quais outros possam confiar. Na prática, esses grupos estabelecem padrões de fato para esquemas de memória, interfaces de ferramentas e protocolos de avaliação, que posteriormente são incorporados às plataformas e aos produtos.

Em síntese, os laboratórios são muito menores em número de funcionários e tendem mais para a ciência; as empresas de plataformas, ferramentas e produtos são muito maiores e tendem mais para a engenharia. Mas em todos os arquétipos, os mesmos ingredientes se repetem, ou seja, agentes, memória, uso de ferramentas e avaliação, e o diferencial está nas pessoas que conseguem transitar ao longo do espectro: inventar quando necessário, projetar quando importante e ponderar sobre segurança, confiabilidade e impacto do produto em todas as etapas.

Responsabilidade	Pesquisa	Pesquisa	(validação)	
[illegible]	[illegible]	ÿ		(ocasionalmente)
[illegible]	[illegible]	(primário)	(publicado)	(primário)
[illegible]		[illegible]	[illegible]	(primário)
[illegible]	ÿ			(extenso)
[illegible]		ÿ	ÿ	(primário)
[illegible]	(primário)			
[illegible]	/			(primário)
[illegible]				(cru)
[illegible]	[illegible]	[illegible]	[illegible]	[illegible]

[illegible]

equipe

Machine Translated by Google

Machine Translated by Google

7 Conclusão

O Continuum de Funções em IA é uma estrutura conceitual para compreender o trabalho moderno em IA: em vez de uma estrutura compartimentada de "pesquisa versus engenharia", temos um espectro onde a maioria dos profissionais atua de forma híbrida, em diferentes graus. Essa mudança é evidente na forma como os principais laboratórios de IA contratam (valorizando conjuntos de habilidades diversificados), na redação das descrições de vagas (enfatizando tanto a expertise em algoritmos quanto em implementação) e na forma como as equipes operam (colaboração transversal desde a concepção da ideia até a implementação). A diluição da fronteira entre pesquisa e engenharia tem se mostrado uma vantagem competitiva para impulsionar as fronteiras da IA – leva a iterações mais rápidas, inovações mais robustas e profissionais capazes de navegar por todo o panorama do desenvolvimento em IA. À medida que os sistemas de IA se tornam mais complexos e impactantes, essa tendência provavelmente continuará: os melhores profissionais de IA serão aqueles que conseguirem transitar com fluidez ao longo do continuum pesquisa-engenharia, incorporando os pontos fortes de ambas as áreas.

A matriz acima representa uma visão generalizada – na prática, os indivíduos frequentemente superam essas expectativas (por exemplo, muitos Engenheiros de Pesquisa também publicam extensivamente, e alguns Cientistas de Pesquisa contribuem com código para produção). O ponto principal é que existe uma convergência significativa, e o sucesso em projetos modernos de IA advém do reconhecimento e aproveitamento desse espectro de funções, em vez de tratar pesquisa e engenharia como silos separados.

Limitações. Nossa base de evidências se apoia em artefatos públicos que podem ser aspiracionais e desiguais entre regiões e tamanhos de empresas. O continuum é uma síntese conceitual, e não um modelo causal, e não medimos diferenças de resultados entre organizações. Como os títulos e responsabilidades estão evoluindo rapidamente, nossas afirmações devem ser interpretadas como limitadas ao período de 2024–2025. Expandir para dados longitudinais e inter-regionais, bem como para hierarquias e avaliações internas anonimizadas, é uma prioridade para trabalhos futuros.

Referências

[1] Anthropic: Os engenheiros aqui fazem muita pesquisa e os pesquisadores fazem muita engenharia (Carreiras na Anthropic). https://www.anthropic.com/careers. Página de Carreiras da Anthropic, declaração de filosofia de contratação (2023)

[2] OpenAI: Engenheiro de Pesquisa – Descrição da vaga. Carreiras na OpenAI (https://openai.com/careers/research-engineer). Acessado em julho de 2025 (2024)

[3] Google DeepMind: Vaga de Engenheiro de Pesquisa (IA para Sustentabilidade). Built In SF Jobs (https://deepmind.google/about/careers/). Prazo de inscrição: 18 de abril de 2025 (2025)

[4] Lakshman, A.: Então, como é ser entrevistado na Meta/Facebook? (Pesquisador Científico). Blog Pessoal (https://www.ahl27.com/posts/2025/02/meta-interview/).
Relato em primeira mão do processo de contratação de Cientistas de Pesquisa da Meta (2025)

[5] Meta: Engenheiro de Pesquisa, IA Generativa (Anúncio de Vaga). Meta Careers (Postagem de Vaga no LinkedIn). Destaca a necessidade de experiência em IA generativa e PNL, avaliação de modelos, etc. (2025). https://ai.meta.com/join-us/ Acesso em 17/07/2025

Machine Translated by Google

[6] Zeng, B.: Como construir uma carreira de sucesso como cientista na Amazon. Amazon Ciência (2022). Artigo do blog de ciência da Amazon.

[7] Amazon.com: Cientista Aplicado, Publicidade (Anúncio de Vaga). Vagas de IA (Londres, Reino Unido). As qualificações preferenciais incluem frameworks de aprendizado profundo e sistemas distribuídos (2023). https://www.amazon.jobs/ Acesso em 17/07/2025

[8] Amazon.com: Principais responsabilidades de cientistas aplicados na Amazon (trecho da publicação da vaga). Amazon Jobs (https://amazon.jobs). ID da vaga 2587481, com ênfase em sistemas distribuídos e integração de aprendizado de máquina (2025)

[9] Shoeybi, M., Patwary, M., Puri, R., LeGresley, P., Casper, J., Catanzaro, B.: Megatron-lm: Treinamento de modelos de linguagem com bilhões de parâmetros usando paralelismo de modelos. arXiv preprint arXiv:1909.08053 (2019)

[10] Rajbhandari, S., Rasley, J., Ruwase, O., He, Y.: ZeRO: Otimizações de memória para treinamento de modelos com trilhões de parâmetros. Em: SC '20: Conferência Internacional de Computação de Alto Desempenho, Redes, Armazenamento e Análise (2020)

[11] Matsukawa, A.: Perguntas frequentes sobre engenharia de pesquisa. https://mtskw.com/posts/re/. Blog postagem (2019)

[12] Huyen, C.: Cientista pesquisador vs. engenheiro pesquisador. https://huyenchip.com/ ml-interviews-book/contents/1.1.2.2-research-scientist-vs.-research-engineer. html. Trecho de Entrevistas sobre Aprendizado de Máquina (livro online) (2022)

[13] Dettmers, T., Lewis, M., Belkada, Y., Zettlemoyer, L.: LLM.int8(): multiplicação de matrizes de 8 bits para transformadores em escala. arXiv preprint arXiv:2208.07339 (2022). Também em Proc. ACM (DOI:10.5555/3600270.3602468)

[14] Frantar, E., Ashkboos, S., Hoefler, T., Alistarh, D.: GPTQ: Quantização pós-treinamento precisa para transformadores generativos pré-treinados. arXiv preprint arXiv:2210.17323 (2022)

[15] Dettmers, T., Pagnoni, A., Holtzman, A., Zettlemoyer, L.: QLoRA: Ajuste fino eficiente de llms quantizados. arXiv preprint arXiv:2305.14314 (2023)

[16] Hinton, G., Vinyals, O., Dean, J.: Destilando o conhecimento em uma rede neural. Em: Workshop de Aprendizado Profundo da NIPS (2015). arXiv:1503.02531

[17] Kaplan, J., McCandlish, S., Henighan, T., Brown, TB, Chess, B., et al.: Leis de escala para modelos de linguagem neural. arXiv preprint arXiv:2001.08361 (2020)

[18] Hoffmann, J., Borgeaud, S., Mensch, A., Buchatskaya, E., Cai, T., et al .: Treinamento de modelos de linguagem grande com otimização de computação. In: NeurIPS (2022). arXiv:2203.15556

[19] Christiano, P., Leike, J., Brown, TB, Martic, M., Legg, S., Amodei, D.: Aprendizagem por reforço profundo a partir de preferências humanas. Em: NeurIPS (2017).

Machine Translated by Google

arXiv:1706.03741

[20] Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., et al.: Treinamento de modelos de linguagem para seguir instruções com feedback humano. Em: NeurIPS (2022). arXiv:2203.02155

[21] Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., Cao, Y.: ReAct: Sinergizando raciocínio e atuação em modelos de linguagem. Em: ICLR (2023). arXiv:2210.03629

[22] Zhou, S., Xu, FF, Zhu, H., Zhou, X., Lo, R., et al.: Webarena: Um ambiente web realista para a construção de agentes autônomos. arXiv preprint arXiv:2307.13854 (2023)

[23] Liu, X., Yu, H., Zhang, H., Xu, Y., Lei, X., et al.: Agentbench: Avaliando LLMs como agentes. arXiv preprint arXiv:2308.03688 (2023)

[24] Wang, G., Xie, Y., Jiang, Y., Mandlekar, A., Xiao, C., Zhu, Y., Fan, L., Anand-kumar, A .: Voyager: Um agente corporificado aberto com grandes modelos de linguagem. Pré-impressão arXiv arXiv:2305.16291 (2023)

[25] Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Zettlemoyer, L., Cancedda, N., Scialom, T.: Toolformer: Os modelos de linguagem podem aprender sozinhos a usar ferramentas. In: NeurIPS (2023). arXiv:2302.04761, DOI:10.5555/3666122.3669119

[26] Wu, Y., Rabe, MN, Hutchins, D., Szegedy, C.: Memorizando transformadores. Em: ICLR (2022). arXiv:2203.08913

[27] Khandelwal, U., Levy, O., Jurafsky, D., Zettlemoyer, L., Lewis, M.: Generalização por meio da memorização: modelos de linguagem de vizinho mais próximo. Em: ICLR (2020). arXiv:1911.00172

[28] Liang, P., Bommasani, R., et al.: Avaliação holística de modelos de linguagem. arXiv preprint arXiv:2211.09110 (2022)

[29] Hendrycks, D., Burns, C., Basart, S., Zou, A., Mazeika, M., Song, D., Stein-hardt, J.: Medindo a compreensão massiva de linguagem multitarefa. Em: ICLR (2021). arXiv:2009.03300

[30] Srivastava, A., Rastogi, A., et al.: Além do jogo da imitação: Quantificando e extrapolando as capacidades dos modelos de linguagem. arXiv preprint arXiv:2206.04615 (2022)

[31] Lin, S., Hilton, J., Evans, O.: Truthfulqa: Medindo como os modelos imitam as falsidades humanas. Em: ACL (Artigos Longos) (2022). arXiv:2109.07958

[32] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., et al.: Geração aumentada por recuperação para tarefas de PNL intensivas em conhecimento. Em: NeurIPS (2020).

Machine Translated by Google

arXiv:2005.11401